

Econometría I

Manual para Ayudantes

Maximiliano Stuardo & Joakina Quezada

2026-08-05

Introducción: ¿Qué es la Econometría?

Regresión Lineal Simple


Definición

Un modelo de Regresión Lineal Simple es aquel modelo en donde nosotros deseamos observar el impacto que tiene una variable independiente (o regresor) X en nuestra variable dependiente (o regresada) Y . De manera poblacional, el un modelo de regresión lineal simple se construye de la siguiente manera:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Donde tendremos a β_0 como intercepto, β_1 como la pendiente de esta recta y por último un término de error ε que interpretaremos más adelante.

La idea de hacer esto es la siguiente:



Teniendo un set de datos donde tenemos muchos puntos dispersos (podrían ser muestras pequeñas, o muestras enormes), intentaremos encontrar la recta que **minimiza la suma cuadrática de los errores**. En primer lugar, se hace con el cuadrado de los errores ya que la suma de los errores es cero. (Ver demostración en Anexo). Y en segundo lugar, minimizar la suma cuadrática de los errores es, ajustar la recta para que los errores que cometemos en nuestra estimación no sean ni tan grandes, ni tan pequeños, definiendo así el método de estimación por **Mínimos Cuadrados Ordinarios (MCO)**. Los estimadores para $\hat{\beta}_0$ y $\hat{\beta}_1$ son (revisar demostración en Anexo):

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{\beta}_1 = \frac{Cov(Y, X)}{Var(X)}$$

Los cuales, por supuestos Gauss-Markov (ver en la siguiente sección) ambos estimadores son insesgados.

Supuestos Gauss-Markov

Para que los estimadores de nuestro modelo obtenidos a través de Mínimos Cuadrados Ordinarios (MCO) sean el **Mejor Estimador Lineal Insesgado (MELI)** o en inglés **Best Linear Unbiased Estimator (BLUE)**, realizaremos una serie de supuestos detallados a continuación:

- 1) **Linealidad en los parámetros:** El modelo es $y = \beta_0 + \beta_1 x_1 + \dots + u$, donde todos los parámetros de la recta no tienen transformaciones no-lineales.
- 2) **Media Condicional Cero (Exogeneidad):** $E(u|x_1, \dots, x_k) = 0$. Este es el supuesto más crítico para la insesgadez.
- 3) **Homocedasticidad:** La varianza del error es constante para cualquier valor de X : $Var(u|X) = \sigma^2$.

- 4) **Mínima Varianza:** Un estimador MELI si o si debe cumplir con tener la mínima varianza, pues, es más fácil concluir que tiene significancia en el modelo.
- 5) **No Autocorrelación:** La autocorrelación de los residuos es 0 ($Cov(\varepsilon_1, \varepsilon_2) = 0$). **Nota: Este supuesto es más fuerte en Series de Tiempo.**
- 6) **No Multicolinealidad Perfecta:** No debe existir una relación lineal perfecta entre las variables independientes, ni se puede escribir alguna variable como combinación lineal de otra. En el caso de la regresión simple, este supuesto se cumple automáticamente.

En un capítulo más adelante veremos que ocurre si se viola el supuesto de **Heterocedasticidad** y de **Exogenidad**.

Especificaciones

No solamente podemos escribir un modelo tal como lo definimos en la primera sección (el cual se conoce como Nivel-Nivel), si no, podemos aplicar transformaciones lineales (la más típica es la transformación logarítmica), que podría quedar de la siguiente manera:

- 1) **Modelo Nivel-Nivel:** $Y = \beta_0 + \beta_1 X + \varepsilon$ Se interpreta como: “Un cambio de 1 unidad en x se asocia con un cambio de β_1 unidades en y ”.
- 2) **Modelo Log-Nivel:** $Y = \beta_0 + \beta_1 \ln(X) + \varepsilon$ Se interpreta como: “Un cambio de 1% en x se asocia con un cambio de $\frac{\beta_1}{100}$ unidades en y ”.
- 3) **Modelo Nivel-Log:** $Y = \beta_0 + \beta_1 X + \varepsilon$ Se interpreta como: “Un cambio de 1 unidad en x se asocia con un cambio de $\beta_1 * 100\%$ en y ”.
- 4) **Modelo Log-Log:** $Y = \beta_0 + \beta_1 \ln(X) + \varepsilon$ Se interpreta como: “Un cambio de 1% en x se asocia con un cambio de $\beta_1\%$ en y ”.

Inferencia Estadística

Ya sabemos cómo crear un modelo, cómo especificarlo y qué cambios hacerle en base a la pregunta de investigación que queremos responder, pero: ¿son nuestros parámetros estimados significativos a nivel individual? Esta pregunta se puede resolver realizando **Pruebas de Hipótesis**.

Una prueba de hipótesis busca concluir si una suposición sobre la población es cierta utilizando datos muestrales. En este caso nos interesa saber si tanto $\hat{\beta}_0$ como $\hat{\beta}_1$ son relevantes o, en términos sencillos, distintos de cero. La notación para una prueba de hipótesis de significancia individual (bilateral) es la siguiente:

$$H_0 : \beta_i = 0$$

$$H_A : \beta_i \neq 0$$

Para realizar una prueba de hipótesis mediante el método del valor crítico, calculamos el estadístico de prueba t . Bajo los supuestos del modelo clásico de regresión lineal (o por el **Teorema del Límite Central** en muestras grandes), este estadístico se construye de la siguiente manera:

$$t_c = \frac{\hat{\beta}_i - \beta_{H_0}}{se(\hat{\beta}_i)}$$

Donde $\beta_{H_0} = 0$ bajo la hipótesis nula, y $se(\hat{\beta}_i)$ es el error estándar del estimador.

Luego, se compara el valor absoluto del estadístico $|t_c|$ con el valor crítico $t_{critico}$ obtenido de la distribución correspondiente (t -Student con $n - k - 1$ grados de libertad o Normal Estándar en muestras grandes cuando $n \rightarrow \infty$) a un nivel de significancia α (niveles habituales de 10%, 5% y 1%).

Para la distribución Normal Estándar, los valores críticos bilaterales más comunes son:

Nivel de Significancia	Valor Crítico
10%	1.645
5%	1.960
1%	2.576

El criterio de rechazo es: Si $|t_c| > t_{critico}$, existe evidencia estadística suficiente para rechazar la hipótesis nula (H_0), lo que significa que el parámetro estimado es **estadísticamente significativo** a un nivel de confianza del $(1 - \alpha)\%$.

De manera equivalente, podemos construir un intervalo de confianza para llegar a la misma conclusión. Si realiza ambos métodos para la misma prueba pero obtiene conclusiones distintas, revise sus cálculos, pues existe un error. La fórmula para construir un intervalo de confianza **bilateral** al $(1 - \alpha)\%$ es:

$$IC = \hat{\beta}_i \pm t_{\alpha/2, n-k-1} \cdot se(\hat{\beta}_i)$$

Si el valor hipotético ($\beta_i = 0$) **no pertenece** al intervalo de confianza, se rechaza la hipótesis nula.

Modelo de Regresión Lineal Múltiple

Definición

A diferencia de un modelo de Regresión Lineal Simple, el modelo de Regresión Lineal Múltiple permite estudiar el impacto de k variables regresoras X en una variable regresada Y . Inicialmente tenemos que:

$$\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{k-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Donde la matriz de Y 's es de orden $\mathbb{M}_{n \times 1}$, la matriz de ε 's es de orden $\mathbb{M}_{n \times 1}$, la matriz de β 's es de orden $\mathbb{M}_{k \times 1}$ y la matriz de covariadas es de orden $\mathbb{M}_{n \times k}$. Finalmente, de manera formal definimos el modelo de regresión múltiple tal que:

$$Y = X\beta + \xi$$

Donde tenemos que el estimador para la matriz de parámetros es la siguiente:

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Y la varianza del estimador es:

$$Var(\beta|X) = \sigma^2 (X^T X)^{-1}$$

Donde la varianza del vector de estimaciones se construye en base al supuesto de Homocedasticidad. (Véase la demostración de ambas en el Anexo)

Bondad de Ajuste

R^2

La bondad de ajuste mide simplemente que porcentaje de la variabilidad de la variable regresada es explicada por la o las variables regresoras. Esto se mide a través del R^2 . Como nota, no hay que obsesionarse con esto ya que, solamente representa lo mencionado en la definición y no así la robustez del modelo (un R^2 alto da una falsa sensación de robustez). El R^2 se obtiene de la siguiente manera:

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$$

Donde $R^2 \in \{0, 1\}$. Usando la siguiente relación: $SCT = SCE + SCR$, si el modelo se ajusta perfectamente, es decir, $SCR = 0$, entonces el $R^2 = 1$. De lo contrario, si el modelo no se ajusta de ninguna manera $SCE = 0$, entonces el $R^2 = 0$.

El R^2 se interpreta como: El modelo logra capturar un $R^2\%$ de la variabilidad de Y .

Overfitting

También, otra de las razones por las cuales no obsesionarse con el R^2 es por el **overfitting**. El overfitting es simplemente el acto de incluir variables inexplicativas a un modelo, generando relaciones espurias. Esto podría “inflar” el R^2 , concluyendo un ajuste que sobredimensiona el ajuste real. Suponga que tenemos el siguiente modelo poblacional (que claro, no conocemos):

$$Y = \gamma_0 + \gamma_1 X_1 + \gamma_2 X_2 + u$$

Donde este modelo tiene un $R^2 = 0.7$. En teoría, intentando estimar este mismo modelo, el máximo R^2 que podemos ostentar sería uno igual a 0.8. Ahora, imaginemos que este fue el modelo que estimamos:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$$

Con un “impresionante” $R^2 = 0.8$. En este caso estamos sobreajustando el modelo, incluyendo una variable que genera una relación espuria con la variable regresada.

Inferencia Estadística

Para esta sección, utilizaremos la misma manera de realizar pruebas de significancia individual que en el capítulo de *Regresión Lineal Simple*. Ahora, añadiremos 3 pruebas de hipótesis importantes para analizar un modelo.

Prueba de Significancia Global

La prueba de hipótesis global tiene por premisa ver si todos los parámetros son significativos en conjunto a nivel poblacional. Por ende, la notación en este caso es la siguiente:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$$

$$H_A : \text{Al menos uno de los } \beta \text{ es distinto de } 0.$$

En este caso utilizaremos nuevamente el método del valor crítico, pero, en este caso nuestro estadístico de prueba distribuye en una distribución F de Snedecor. Nuestro estadístico de prueba es el siguiente:

$$F_c = \frac{R^2/k}{(1 - R^2)/(n - k - 1)}$$

Donde compararemos este estadístico con un valor crítico F , que depende de los grados de libertad del numerador y grados de libertad del denominador, y, la manera de comparar es la misma: Si $F_c > F_{df1, df2}$ (donde $df1 = k$ y $df2 = n - k - 1$) entonces existe suficiente evidencia estadística para rechazar la hipótesis nula, es decir, los parámetros son significativos en conjunto.

Prueba de Significancia de Combinaciones de Parámetros

Inicialmente hemos hecho pruebas de hipótesis para significancia individual de un solo parámetro. Pero, también nos interesaría estudiar por ejemplo si los efectos de dos variables son iguales, es decir $\beta_1 = \beta_2$. En este caso la idea cambia un poco, pues, tenemos que realizar ciertas transformaciones para hacer el proceso más sencillo. La notación para este ejemplo sería:

$$\begin{aligned} H_0 : \beta_1 - \beta_2 &= 0 \\ H_A : \beta_1 - \beta_2 &\neq 0 \end{aligned}$$

Y así, tenemos que obtener un estadístico t_c el cual obtenemos derivando de la misma fórmula de la prueba de hipótesis individual pero cambiando ciertas cosas:

$$t_c = \frac{(\widehat{\beta}_1 - \widehat{\beta}_2) - \beta_{H_0}}{\sqrt{Var(\widehat{\beta}_1 - \widehat{\beta}_2)}}$$

Donde luego, haremos la misma comparación, con los mismos valores de la distribución t o de una distribución normal estándar mediante TLC.

Múltiples Restricciones Lineales

Ya hemos realizado distintos tipos de prueba de hipótesis, pero, de todas maneras también querríamos estudiar si es que varias restricciones se cumplen a la vez, es decir algo de este estilo:

$$\begin{aligned} H_0 : \beta_1 + \beta_3 &= 3 \\ \frac{1}{3}\beta_1 + \beta_2 &= 4 \end{aligned}$$

H_1 = Al menos una de las restricciones no se cumple

Entonces no podemos hacer una prueba de hipótesis con un estadístico t normal, si no más bien, vamos a estimar un modelo (a través de MCO) en donde SI SE CUMPLAN estas restricciones. Entonces sea el modelo acorde al ejemplo definido como $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$ Vamos a armar una matriz $R\beta = q$ donde R son los coeficientes de los betas bajo la hipótesis nula, β nuestro vector de betas y q el lado derecho del igual de nuestras hipótesis nulas. Entonces definimos:

$$\begin{aligned} R &= \begin{pmatrix} 0 & 1 & 0 & 1 \\ 0 & \frac{1}{3} & 1 & 0 \end{pmatrix} \\ q &= \begin{pmatrix} 3 \\ 4 \end{pmatrix} \end{aligned}$$

y planteamos el problema que deseamos resolver:

$$\begin{aligned} \min : & U^T U \\ \text{s.a} : & R\beta = q \end{aligned}$$

Y sabemos que $U^T U = [Y - X\beta]^T [Y - X\beta]$.

Por lo tanto resolveremos el problema de minimización a través de multiplicadores de Lagrange, entonces el Lagrangeano nos queda:

$$\mathcal{L} = [Y - X\beta]^T [Y - X\beta] + 2\lambda[R\beta - q]$$

Y por tanto, para resolver se debe cumplir que:

$$\frac{\partial \mathcal{L}}{\partial \lambda} = 0 \wedge \frac{\partial \mathcal{L}}{\partial \beta} = 0$$

La primera ecuación corresponde a la restricción, y la segunda ecuación correspondería a:

$$2(X^T X)\beta - 2X^T Y + 2R^T \lambda = 0$$

Finalmente, desarrollando esto (véase en el Anexo) nuestro estimador de este modelo con las restricciones impuestas, al cual llamaremos **Mínimos Cuadrados Restringidos** es el siguiente:

$$\tilde{\beta} = (X^T X)^{-1} X^T Y - (X^T X)^{-1} R^T \lambda$$

Si nosotros deseamos calcular la varianza del estimador, tenemos lo siguiente:

$$V(\tilde{\beta}) = V(\hat{\beta}) - \text{terminos positivos}$$

Podemos ver entonces que, la varianza del estimador de MCR es menor a la de MCO **siempre y cuando las restricciones NO SE CUMPLAN**, en el caso contrario, la varianza de MCR y la varianza de MCO son iguales.

Luego de esto, derivando obtenemos que:

$$\tilde{\xi}^T \tilde{\xi} = \hat{\xi}^T \hat{\xi} + (\tilde{\beta} - \hat{\beta})^T X^T X - 2(\tilde{\beta} - \hat{\beta})^T X^T \hat{\xi}$$

Concluyendo entonces que:

$$\tilde{\xi}^T \tilde{\xi} \geq \hat{\xi}^T \hat{\xi}$$

Por lo tanto, así $F_c = \frac{(\tilde{\xi}^T \tilde{\xi} - \hat{\xi}^T \hat{\xi})/q}{\hat{\xi}^T \hat{\xi}/(n-k)}$. Y amplificando por $\frac{1}{SCT}$ tenemos que:

$$F_c = \frac{(R^2 - R_r^2)/q}{(1 - R^2)/(n - k - 1)}$$

Donde q es el número de restricciones.

Variables Dummy

Una variable Dummy (o típicamente variable indicadora) es una variable que toma el valor de 1 o 0 dependiendo de si se cumple o no una condición. Por ejemplo, si queremos estudiar el efecto de ser hombre o mujer en los ingresos, podemos crear una variable Dummy que tome el valor de 1 si la persona es hombre y 0 si es mujer.

Modelo de Regresión Simple con Variables Dummy

En términos univariados el modelo queda escrito de la siguiente manera:

$$Y = \beta_0 + \beta_1 D + \varepsilon$$


Donde el valor esperado para una persona hombre es:

$$E(Y|D = 1) = \beta_0 + \beta_1$$

Así, el valor esperado para una persona mujer es:

$$E(Y|D = 0) = \beta_0$$

La interpretación de β_1 es el cambio en los ingresos esperado al cambiar de mujer a hombre. Gráficamente, el modelo se ve de la siguiente manera:



Modelo de Regresión Múltiple con Variables Dummy

En contextos multivariados, podemos incluir variables Dummy junto con otras variables continuas. Por ejemplo, si queremos estudiar el efecto de la educación y el género en los ingresos, podemos tener un modelo como:

$$Y = \beta_0 + \beta_1 D + \beta_2 X + \varepsilon$$

Donde la interpretación cambiará dependiendo de la variable Dummy y la variable continua. En este caso, β_1 representará el efecto del género en los ingresos, mientras que β_2 representará el efecto de la educación en los ingresos. Por lo tanto, el valor esperado de los ingresos para una persona hombre con un nivel de educación X será:


$$E(Y|D = 1, X) = \beta_0 + \beta_1 + \beta_2 X$$

Así, el valor esperado para una persona mujer con el mismo nivel de educación X será:

$$E(Y|D = 0, X) = \beta_0 + \beta_2 X$$

La interpretación de β_1 es el cambio en los ingresos esperado al cambiar de mujer a hombre, manteniendo constante el nivel de educación.

Gráficamente, el modelo se ve de la siguiente manera:



Interacciones

En nuestro modelo, también podemos incluir interacciones entre variables Dummy y continuas. Por ejemplo, si queremos ver si el efecto de la educación en los ingresos difiere entre hombres y mujeres, podemos incluir un término de interacción:

$$Y = \beta_0 + \beta_1 D + \beta_2 X + \beta_3 (D \times X) + \varepsilon$$

En este caso, β_3 nos dirá si el efecto de la educación en los ingresos es diferente para hombres y mujeres. Si β_3 es positivo, significa que el retorno a la educación es mayor para los hombres que para las mujeres, y viceversa.

Entonces, el valor esperado de los ingresos para una persona hombre con un nivel de educación X será:


$$E(Y|D = 1, X) = \beta_0 + \beta_1 + \beta_2 X + \beta_3 X$$

$$E(Y|D = 1, X) = (\beta_0 + \beta_1) + (\beta_2 + \beta_3)X$$

Así mismo, el efecto de los ingresos de una persona mujer con el mismo nivel de educación X será:

$$E(Y|D = 0, X) = \beta_0 + \beta_2 X$$

Gráficamente, el modelo con interacción se ve de la siguiente manera:



Heterocedasticidad

Definición

Anteriormente, por supuestos Gauss-Markov habíamos asumido que estábamos en presencia de homocedasticidad, es decir, la varianza de los residuos es constante. Pero, lamentablemente en la realidad esto es casi imposible que ocurra. Definimos anteriormente, la varianza del parámetro como:

$$V(\hat{\beta}) = (X^T X)^{-1} X^T E[UU^T] X (X^T X)^{-1}$$


Donde asumíamos que $E[UU^T] = \sigma^2 I$ obviamente por el supuesto de Homocedasticidad. En presencia de heterocedasticidad esto ya no ocurre, por lo que a esta expresión la denotaremos por Ω . Por tanto la varianza del parámetro queda como:

$$V(\hat{\beta}) = (X^T X)^{-1} X^T \Omega X (X^T X)^{-1}$$

Donde Ω es una matriz diagonal con elementos σ_i^2 en la diagonal, es decir, la varianza de los residuos no es constante. Por lo tanto, el estimador de MCO sigue siendo insesgado, pero ya no es eficiente. Por lo que necesitamos un estimador robusto a heterocedasticidad.

Gráficamente, la heterocedasticidad se puede presentar de la siguiente forma:

Patrones Comunes de Heterocedasticidad en los Residuos



Si observan, a medida que aumenta el valor de X , en el caso heterocedástico vemos que cada vez más aumenta el error. Esto podría suceder de forma de abanico creciente, decreciente o en forma de U, cualquiera de las tres mencionadas son casos de heterocedasticidad. Lo que a nosotros nos gustaría ver es que se forme una nube sin forma, que en promedio oscile en un valor constante para cada valor de X .

Consecuencias para MCO.

Las consecuencias que sufrirían nuestros parámetros estimados por MCO son que dejan de ser eficientes (ya no son BLUE) y la inferencia es inválida, pues, los estadísticos de prueba y los intervalos de confianza están “manchados” por este problema de heterocedasticidad.

Entonces, en teoría los argumentos Gauss-Markov ya no se cumplen, por lo que necesitamos solucionar este problema, y para ello existen diversas soluciones, dentro de las cuales están:

- 1) **Trasformaciones de Variables:** Por ejemplo, si tenemos un modelo de Nivel-Nivel, podríamos transformarlo a Log-Log, lo cual podría ayudar a estabilizar la varianza de los residuos.
- 2) **Mínimos Cuadrados Generalizados (MCG):** Este método es una extensión de MCO, que permite corregir la heterocedasticidad, pero requiere conocer la forma funcional de la heterocedasticidad.
- 3) **Mínimos Cuadrados Ponderados (MCP):** Este método es una variante de MCG, que permite corregir la heterocedasticidad, pero requiere conocer la forma funcional de la heterocedasticidad.
- 4) **Estimadores Robustos a Heterocedasticidad:** Este método es una variante de MCO, que permite corregir la heterocedasticidad, pero no requiere conocer la forma funcional de la heterocedasticidad. En R, se puede implementar con el paquete `sandwich`.

Detección de Heterocedasticidad

Para detectar heterocedasticidad, existen dos maneras principales para detectarlo, las cuales son:

- 1) **Test de Breusch-Pagan:** Este test es un test de hipótesis que busca determinar si la varianza de los residuos es constante o no. La hipótesis nula es que la varianza es constante (homocedasticidad) y la alternativa es que la varianza no es constante (heterocedasticidad). El estadístico de prueba sigue una distribución Chi-cuadrado con grados de libertad igual al número de variables independientes en el modelo. Matemáticamente, el test de Breusch-Pagan se puede expresar como:

$$BP = n \cdot R_{\text{aux}}^2$$

Donde el R_{aux}^2 es el R^2 de la regresión auxiliar, que se obtiene al regredir los residuos al cuadrado del modelo original sobre las variables independientes del modelo original, tal que:

$$e_i^2 = \alpha + \beta_1 X_1 + \beta_2 X_2 + \epsilon_i$$

La conclusión se obtiene a través de comparar el estadístico de prueba con el valor crítico de la distribución Chi-cuadrado con grados de libertad igual al número de variables independientes en el modelo. Si el estadístico de prueba es mayor que el valor crítico, se rechaza la hipótesis nula y se concluye que hay evidencia de heterocedasticidad.

- 2) **Test de White:** Este test es un test de hipótesis que busca determinar si la varianza de los residuos es constante o no. La hipótesis nula es que la varianza es constante (homocedasticidad) y la alternativa es que la varianza no es constante (heterocedasticidad). El estadístico de prueba sigue una distribución Chi-cuadrado con grados de libertad igual al número de variables independientes en el modelo más el número de variables independientes al cuadrado. Matemáticamente el test de White es exactamente igual que el test de Breusch-Pagan, pero la diferencia es que en la regresión auxiliar se incluyen los términos al cuadrado y los términos de interacción de las variables independientes del modelo original, tal que:

$$e_i^2 = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1^2 + \beta_4 X_2^2 + \beta_5 (X_1 \times X_2) + \epsilon_i$$

Y la conclusión es exactamente la misma que en el test de Breusch-Pagan, se compara el estadístico de prueba con el valor crítico de la distribución Chi-cuadrado con grados de libertad igual al número de variables independientes en el modelo más el número de variables independientes al cuadrado. Si el estadístico de prueba es mayor que el valor crítico, se rechaza la hipótesis nula y se concluye que hay evidencia de heterocedasticidad.

Endogeneidad: Variables Instrumentales